МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра МОЭВМ

ОТЧЕТ

по лабораторной работе № 3

по дисциплине «Машинное обучение»

Тема: Частотный анализ

Студенты гр. 6304 Григорьев И.С.

Преподаватель Жангиров Т.Р.

Санкт-Петербург

2020

Цель работы

Ознакомиться с методами частотного анализа из библиотеки MLxtend

Ход работы

Загрузка данных

```
import pandas as pd
import numpy as np
from mlxtend.preprocessing import TransactionEncoder
from mlxtend.frequent_patterns import apriori
import matplotlib.pyplot as plt
```

```
all_data = pd.read_csv('dataset_group.csv', header=None, names=['date', 'transaction_id', 'item'])
all_data
```

	date	transaction_id	item
0	2000-01-01	1	yogurt
1	2000-01-01	1	pork
2	2000-01-01	1	sandwich bags
3	2000-01-01	1	lunch meat
4	2000-01-01	1	all- purpose
...	...	...	...
22338	2002-02-26	1139	soda
22339	2002-02-26	1139	laundry detergent
22340	2002-02-26	1139	vegetables
22341	2002-02-26	1139	shampoo
22342	2002-02-26	1139	vegetables

22343 rows × 3 columns

Список всех id

```
unique_id = all_data.transaction_id.unique()
print('Количество транзакций:', len(unique_id))
```

```
Количество транзакций: 1139
```

Список товаров

```
items = all_data.item.unique()
print('Количество товаров:', len(items))
```

```
Количество товаров: 38
```

Списки товаров для каждого покупателя

```
dataset = [[elem for elem in all_data[all_data.transaction_id == id].item if elem in items] for id in u
nique_id]
```

Подготовка данных

```
te = TransactionEncoder()
te_ary = te.fit_transform(dataset)
df = pd.DataFrame(te_ary, columns=te.columns_)
df
```

	all-purpose	aluminum foil	bagels	beef	butter	cereals	cheeses	coffee/tea	dinner rolls	dishwashing liquid/detergent	...	shampoo	soap	soda	spagh sau
0	True	True	False	True	True	False	False	False	True	False	...	True	True	True	Fa
1	False	True	False	False	False	True	True	False	False	True	...	True	False	False	Fa
2	False	False	True	False	False	True	True	False	True	False	...	True	True	True	T
3	True	False	False	False	False	True	False	False	False	False	...	False	False	True	Fa
4	True	False	False	False	False	False	False	False	True	False	...	False	False	True	T
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	
1134	True	False	False	True	False	True	True	True	True	True	...	True	True	False	Fa
1135	False	False	False	False	False	True	True	True	True	True	...	False	True	False	T
1136	False	False	True	True	False	False	False	False	True	True	...	True	True	False	Fa
1137	True	False	False	True	False	False	True	False	False	False	...	False	True	True	T
1138	False	False	False	False	False	False	False	False	False	False	...	True	False	True	Fa

1139 rows × 38 columns

Данные преобрзованы с помощью TransactionEncoder в датасет, который представляет собой бинарную матрицу размера 1139x38. Строки - идентификаторы транзакций (покупатели), столбцы - элементы (товары), на пересечении - покупал ли пользователь данный товар.

Ассоциативный анализ с использованием алгоритма Apriori

1) Получены часто встречающиеся наборы товаров с минимальным уровнем поддержки 0.3. Это значит, что данные наборы товаров покупали не менее 30% покупателей. Минимальный размер набора товаров - 1, максимальный - 2.

```
results = apriori(df, min_support=0.3, use_colnames=True)
results
```

	support	itemsets
0	0.374890	(all- purpose)
1	0.384548	(aluminum foil)
2	0.385426	(bagels)
3	0.374890	(beef)
4	0.367867	(butter)
5	0.395961	(cereals)
6	0.390694	(cheeses)
7	0.379280	(coffee/tea)
8	0.388938	(dinner rolls)
9	0.388060	(dishwashing liquid/detergent)
10	0.389816	(eggs)
11	0.352941	(flour)
12	0.370500	(fruits)
13	0.345917	(hand soap)
14	0.398595	(ice cream)
15	0.375768	(individual meals)
16	0.376646	(juice)
17	0.371378	(ketchup)
18	0.378402	(laundry detergent)
19	0.395083	(lunch meat)
20	0.380158	(milk)
21	0.375768	(mixes)
22	0.362599	(paper towels)
23	0.371378	(pasta)
24	0.355575	(pork)
25	0.421422	(poultry)
26	0.367867	(sandwich bags)
27	0.349429	(sandwich loaves)
28	0.368745	(shampoo)
29	0.379280	(soap)
30	0.390694	(soda)
31	0.373134	(spaghetti sauce)
32	0.360843	(sugar)
33	0.378402	(toilet paper)
34	0.369622	(tortillas)
35	0.739245	(vegetables)
36	0.394205	(waffles)
37	0.384548	(yogurt)
38	0.310799	(aluminum foil, vegetables)
39	0.300263	(bagels, vegetables)
40	0.310799	(cereals, vegetables)
41	0.309043	(cheeses, vegetables)
42	0.308165	(vegetables, dinner rolls)
43	0.306409	(dishwashing liquid/detergent, vegetables)
44	0.326602	(eggs, vegetables)
45	0.302897	(ice cream, vegetables)
46	0.309043	(laundry detergent, vegetables)
47	0.311677	(lunch meat, vegetables)
48	0.331870	(poultry, vegetables)
49	0.305531	(soda, vegetables)
50	0.315189	(waffles, vegetables)
51	0.319579	(yogurt, vegetables)

2) Для минимального уровня поддержки 0.3 получены наборы, состоящие только из одного товара.

```
results = apriori(df, min_support=0.3, use_colnames=True, max_len=1)
results
```

	support	itemsets
0	0.374890	(all- purpose)
1	0.384548	(aluminum foil)
2	0.385426	(bagels)
3	0.374890	(beef)
4	0.367867	(butter)
5	0.395961	(cereals)
6	0.390694	(cheeses)
7	0.379280	(coffee/tea)
8	0.388938	(dinner rolls)
9	0.388060	(dishwashing liquid/detergent)
10	0.389816	(eggs)
11	0.352941	(flour)
12	0.370500	(fruits)
13	0.345917	(hand soap)
14	0.398595	(ice cream)
15	0.375768	(individual meals)
16	0.376646	(juice)
17	0.371378	(ketchup)
18	0.378402	(laundry detergent)
19	0.395083	(lunch meat)
20	0.380158	(milk)
21	0.375768	(mixes)
22	0.362599	(paper towels)
23	0.371378	(pasta)
24	0.355575	(pork)
25	0.421422	(poultry)
26	0.367867	(sandwich bags)
27	0.349429	(sandwich loaves)
28	0.368745	(shampoo)
29	0.379280	(soap)
30	0.390694	(soda)
31	0.373134	(spaghetti sauce)
32	0.360843	(sugar)
33	0.378402	(toilet paper)
34	0.369622	(tortillas)
35	0.739245	(vegetables)
36	0.394205	(waffles)
37	0.384548	(yogurt)

3) Для минимального уровня поддержки 0.3 получены наборы, состоящие только из двух товаров.

```
results = apriori(df, min_support=0.3, use_colnames=True)
results['length'] = results['itemsets'].apply(lambda x: len(x))
results = results[results['length'] == 2]
print(results)
print('\nCount of result itemstes = ', len(results))
```

```
     support                                  itemsets  length
38  0.310799                 (aluminum foil, vegetables)       2
39  0.300263                        (bagels, vegetables)       2
40  0.310799                      (cereals, vegetables)       2
41  0.309043                      (cheeses, vegetables)       2
42  0.308165                  (vegetables, dinner rolls)       2
43  0.306409  (dishwashing liquid/detergent, vegetables)       2
44  0.326602                         (eggs, vegetables)       2
45  0.302897                    (ice cream, vegetables)       2
46  0.309043            (laundry detergent, vegetables)       2
47  0.311677                    (lunch meat, vegetables)       2
48  0.331870                       (poultry, vegetables)       2
49  0.305531                          (soda, vegetables)       2
50  0.315189                      (waffles, vegetables)       2
51  0.319579                       (yogurt, vegetables)       2

Count of result itemstes =  14
```

4) Построена зависимость количества наборов от уровня поддержки. Красными точками отмечены уровни поддержки, при которых перестают генерироваться наборы размера 4, 3, 2, 1.

```
min_supports = np.arange(0.05, 1, 0.01)
items_set_count = np.array([])
max_len = -1
for min_support in min_supports:
    results = apriori(df, min_support=min_support, use_colnames=True)
    results['length'] = results['itemsets'].apply(lambda x: len(x))
    max_len_curr = np.max(results['length'])
    if (max_len == -1):
        max_len = max_len_curr
    if (max_len != max_len_curr):
        plt.scatter(min_support, len(results), c='r')
        plt.text(min_support, len(results) + 500, str(max_len))
        max_len = max_len_curr
    if (np.isnan(max_len_curr)):
        break
    items_set_count = np.append(items_set_count, len(results))

plt.plot(min_supports[:len(items_set_count)], items_set_count)
plt.title('Зависимость количества наборов от уровня поддержки')
plt.xlabel('Уровень поддержки')
plt.ylabel('Количество наборов')
plt.show()
```

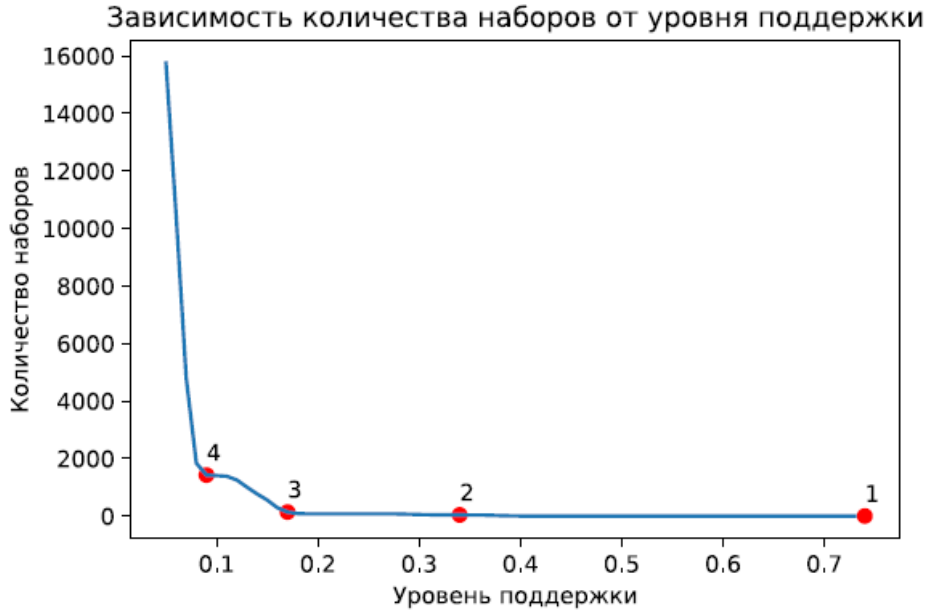

5) Построен датасет только из тех элементов, которые попадают в наборы размером 1, при уровне поддержки 0.38.

```
results = apriori(df, min_support=0.38, use_colnames=True, max_len=1)
new_items = [list(elem)[0] for elem in results['itemsets']]
new_dataset = [[elem for elem in all_data[all_data.transaction_id == id].item if elem in new_items] for
 id in unique_id]
results
```

	support	itemsets
0	0.384548	(aluminum foil)
1	0.385426	(bagels)
2	0.395961	(cereals)
3	0.390694	(cheeses)
4	0.388938	(dinner rolls)
5	0.388060	(dishwashing liquid/detergent)
6	0.389816	(eggs)
7	0.398595	(ice cream)
8	0.395083	(lunch meat)
9	0.380158	(milk)
10	0.421422	(poultry)
11	0.390694	(soda)
12	0.739245	(vegetables)
13	0.394205	(waffles)
14	0.384548	(yogurt)

6) Полученный датасет приведен к необходимому для работы формату.

```
te = TransactionEncoder()
te_ary = te.fit_transform(new_dataset)
new_df = pd.DataFrame(te_ary, columns=te.columns_)
new_df
```

	aluminum foil	bagels	cereals	cheeses	dinner rolls	dishwashing liquid/detergent	eggs	ice cream	lunch meat	milk	poultry	soda	vegetables	waffles	yogu
0	True	False	False	False	True	False	False	True	True	False	False	True	True	False	Tru
1	True	False	True	True	False	True	False	False	False	True	False	False	True	True	Tru
2	False	True	True	True	True	False	True	True	True	True	True	True	True	False	Fals
3	False	False	True	False	False	False	False	False	True	False	False	True	False	False	Fals
4	False	False	False	False	True	False	True	False	False	True	True	True	True	True	Tru
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	
1134	False	False	True	True	True	True	False	True	False	False	True	False	False	False	Fals
1135	False	False	True	True	True	True	True	False	True	True	True	False	True	False	Fals
1136	False	True	False	False	True	True	True	False	True	False	True	False	True	False	Tru
1137	False	False	False	True	False	False	False	False	False	True	True	True	True	True	Tru
1138	False	False	False	False	False	False	False	False	False	False	False	True	True	False	Fals

1139 rows × 15 columns

7) Проведен ассоциативный анализ при уровне поддержки 0.3 для нового датасета. В результате отсутствуют продукты (и их наборы), чей уровень поддержки был меньше, чем 0.38. Результат данного ассоциативного анализа входит в результат анализа для исходного датасета.

```
results = apriori(new_df, min_support=0.3, use_colnames=True)
results
```

	support	itemsets
0	0.384548	(aluminum foil)
1	0.385426	(bagels)
2	0.395961	(cereals)
3	0.390694	(cheeses)
4	0.388938	(dinner rolls)
5	0.388060	(dishwashing liquid/detergent)
6	0.389816	(eggs)
7	0.398595	(ice cream)
8	0.395083	(lunch meat)
9	0.380158	(milk)
10	0.421422	(poultry)
11	0.390694	(soda)
12	0.739245	(vegetables)
13	0.394205	(waffles)
14	0.384548	(yogurt)
15	0.310799	(aluminum foil, vegetables)
16	0.300263	(bagels, vegetables)
17	0.310799	(cereals, vegetables)
18	0.309043	(cheeses, vegetables)
19	0.308165	(vegetables, dinner rolls)
20	0.306409	(dishwashing liquid/detergent, vegetables)
21	0.326602	(eggs, vegetables)
22	0.302897	(ice cream, vegetables)
23	0.311677	(lunch meat, vegetables)
24	0.331870	(poultry, vegetables)
25	0.305531	(soda, vegetables)
26	0.315189	(waffles, vegetables)
27	0.319579	(yogurt, vegetables)

8) Проведен ассоциативный анализ при уровне поддержки 0.15 для нового датасета. Выведены все наборы, размер которых больше 1 и в которых есть 'yogurt' или 'waffles'.

```
results = apriori(new_df, min_support=0.15, use_colnames=True)
results['cond'] = results['itemsets'].apply(lambda iset: len(iset) > 1 and ('yogurt' in iset or 'waffle
s' in iset))
results = results[results['cond']]
del results['cond']
print(results)
print('\nCount of result itemstes = ', len(results))
```

```
      support                                itemsets
27   0.169447                (waffles, aluminum foil)
28   0.177349                 (yogurt, aluminum foil)
40   0.159789                       (waffles, bagels)
41   0.162423                        (yogurt, bagels)
52   0.160667                      (cereals, waffles)
53   0.172081                       (cereals, yogurt)
63   0.172959                      (waffles, cheeses)
64   0.172081                       (yogurt, cheeses)
73   0.169447                (waffles, dinner rolls)
74   0.166813                 (yogurt, dinner rolls)
82   0.175593  (dishwashing liquid/detergent, waffles)
83   0.158033   (dishwashing liquid/detergent, yogurt)
90   0.169447                        (waffles, eggs)
91   0.174715                         (yogurt, eggs)
97   0.172959                  (waffles, ice cream)
98   0.156277                   (yogurt, ice cream)
103  0.184372                 (waffles, lunch meat)
104  0.161545                  (yogurt, lunch meat)
108  0.167691                        (milk, yogurt)
111  0.166813                   (waffles, poultry)
112  0.180860                    (yogurt, poultry)
114  0.177349                      (waffles, soda)
115  0.167691                       (yogurt, soda)
116  0.315189                 (waffles, vegetables)
117  0.319579                  (yogurt, vegetables)
118  0.173837                      (waffles, yogurt)
119  0.152766  (yogurt, aluminum foil, vegetables)
128  0.157155                 (yogurt, eggs, vegetables)
130  0.157155           (waffles, lunch meat, vegetables)
131  0.152766               (yogurt, poultry, vegetables)

Count of result itemstes =  30
```

9) Построен датасет, из тех элементов, которые не попали в датасет из п. 6. Датасет приведен к удобному для анализа виду.

```
diff_items = set(list(df)) - set(list(new_df))
diff_dataset = [[elem for elem in all_data[all_data.transaction_id == id].item if elem in diff_items] f
or id in unique_id]
te = TransactionEncoder()
te_ary = te.fit_transform(diff_dataset)
diff_df = pd.DataFrame(te_ary, columns=te.columns_)
diff_df
```

	all-purpose	beef	butter	coffee/tea	flour	fruits	hand soap	individual meals	juice	ketchup	...	pasta	pork	sandwich bags	sandwich loaves	shampoo
0	True	True	True	False	True	False	False	False	False	False	...	False	True	True	False	True
1	False	False	False	False	False	False	True	True	False	False	...	False	False	True	False	True
2	False	False	False	False	False	False	True	False	False	True	...	False	True	False	True	True
3	True	False	False	False	False	False	False	False	True	False	...	False	False	False	False	False
4	True	False	False	False	True	False	True	True	False	False	...	True	True	False	True	False
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
1134	True	True	False	True	False	True	True	False	True	False	...	False	True	True	False	True
1135	False	False	False	True	False	False	True	True	False	False	...	True	False	False	False	False
1136	False	True	False	False	False	False	True	True	True	False	...	False	True	False	False	True
1137	True	True	False	False	False	False	False	False	False	True	...	False	False	True	False	False
1138	False	False	False	False	False	False	False	False	False	False	...	False	False	False	False	True

1139 rows × 23 columns

10) Проведен ассоциативный анализ при уровне поддержки 0.3 для нового датасета (diff_df).

```
results = apriori(diff_df, min_support=0.3, use_colnames=True)
results
```

	support	itemsets
0	0.374890	(all- purpose)
1	0.374890	(beef)
2	0.367867	(butter)
3	0.379280	(coffee/tea)
4	0.352941	(flour)
5	0.370500	(fruits)
6	0.345917	(hand soap)
7	0.375768	(individual meals)
8	0.376646	(juice)
9	0.371378	(ketchup)
10	0.378402	(laundry detergent)
11	0.375768	(mixes)
12	0.362599	(paper towels)
13	0.371378	(pasta)
14	0.355575	(pork)
15	0.367867	(sandwich bags)
16	0.349429	(sandwich loaves)
17	0.368745	(shampoo)
18	0.379280	(soap)
19	0.373134	(spaghetti sauce)
20	0.360843	(sugar)
21	0.378402	(toilet paper)
22	0.369622	(tortillas)

11) Написано правило для вывода всех наборов, в которых хотя бы два элемента начинаются на 's'.

```
results = apriori(df, min_support=0.1, use_colnames=True)
results = results[results['itemsets'].apply(lambda iset: len([item for item in iset if item.startswith(
's')]) >= 2)]
results
```

	support	itemsets
675	0.137840	(sandwich loaves, sandwich bags)
676	0.146620	(shampoo, sandwich bags)
677	0.158911	(soap, sandwich bags)
678	0.162423	(soda, sandwich bags)
679	0.147498	(spaghetti sauce, sandwich bags)
680	0.131694	(sugar, sandwich bags)
686	0.150132	(shampoo, sandwich loaves)
687	0.158033	(sandwich loaves, soap)
688	0.141352	(sandwich loaves, soda)
689	0.150132	(spaghetti sauce, sandwich loaves)
690	0.136962	(sandwich loaves, sugar)
696	0.151010	(shampoo, soap)
697	0.150132	(shampoo, soda)
698	0.139596	(spaghetti sauce, shampoo)
699	0.147498	(shampoo, sugar)
705	0.174715	(soap, soda)
706	0.160667	(spaghetti sauce, soap)
707	0.154522	(sugar, soap)
713	0.167691	(spaghetti sauce, soda)
714	0.162423	(sugar, soda)
720	0.144864	(spaghetti sauce, sugar)
1351	0.115013	(sandwich loaves, sandwich bags, vegetables)
1352	0.122915	(shampoo, sandwich bags, vegetables)
1353	0.129939	(soap, sandwich bags, vegetables)
1354	0.129061	(soda, sandwich bags, vegetables)
1355	0.123793	(spaghetti sauce, sandwich bags, vegetables)
1356	0.113257	(sugar, sandwich bags, vegetables)
1361	0.129061	(shampoo, sandwich loaves, vegetables)
1362	0.132572	(sandwich loaves, soap, vegetables)
1363	0.121159	(sandwich loaves, soda, vegetables)
1364	0.122915	(spaghetti sauce, sandwich loaves, vegetables)
1365	0.121159	(sandwich loaves, sugar, vegetables)
1370	0.124671	(shampoo, soap, vegetables)
1371	0.128183	(shampoo, soda, vegetables)
1372	0.117647	(spaghetti sauce, shampoo, vegetables)
1373	0.122037	(shampoo, sugar, vegetables)
1378	0.141352	(soap, soda, vegetables)
1379	0.136962	(spaghetti sauce, soap, vegetables)
1380	0.127305	(sugar, soap, vegetables)
1385	0.138718	(spaghetti sauce, soda, vegetables)
1386	0.136084	(sugar, soda, vegetables)
1391	0.124671	(spaghetti sauce, sugar, vegetables)

12) Написано правило для вывода всех наборов, для которых уровень поддержки изменяется от 0.1 до 0.25.

```
results = apriori(df, min_support=0.1, use_colnames=True)
results = results[results['support'].apply(lambda sup: sup > 0.1 and sup < 0.25)]
results
```

	support	itemsets
38	0.157155	(all- purpose, aluminum foil)
39	0.150132	(all- purpose, bagels)
40	0.144864	(all- purpose, beef)
41	0.147498	(all- purpose, butter)
42	0.151010	(all- purpose, cereals)
...	...	...
1401	0.135206	(toilet paper, waffles, vegetables)
1402	0.130817	(toilet paper, yogurt, vegetables)
1403	0.121159	(vegetables, waffles, tortillas)
1404	0.130817	(vegetables, yogurt, tortillas)
1405	0.146620	(waffles, yogurt, vegetables)

1331 rows × 2 columns

Выводы

В ходе лабораторной работы изучены методы частотного анализа из библиотеки MLxtend: метод Apriori позволяет выделить частовстречающиеся наборы элементов для заданного минимального уровня поддержки. Увеличение уровня поддержки в первую очередь уменьшает количество наборов большей длины.