МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра МО ЭВМ

ОТЧЕТ

по лабораторной работе №1

по дисциплине «Машинное обучение»

Тема: Предобработка данных

Студент гр. 6307 _____ Давыдова Н. П.

Преподаватель _____ Жангиров Т. Р.

Санкт-Петербург

2020

Содержание

Загрузка данных

1. Загрузила датасет по ссылке: https://www.kaggle.com/andrewmvd/heart-failure-clinical-dat

2. Загрузила датасет в датафрейм, и исключила бинарные признаки и признак времени.

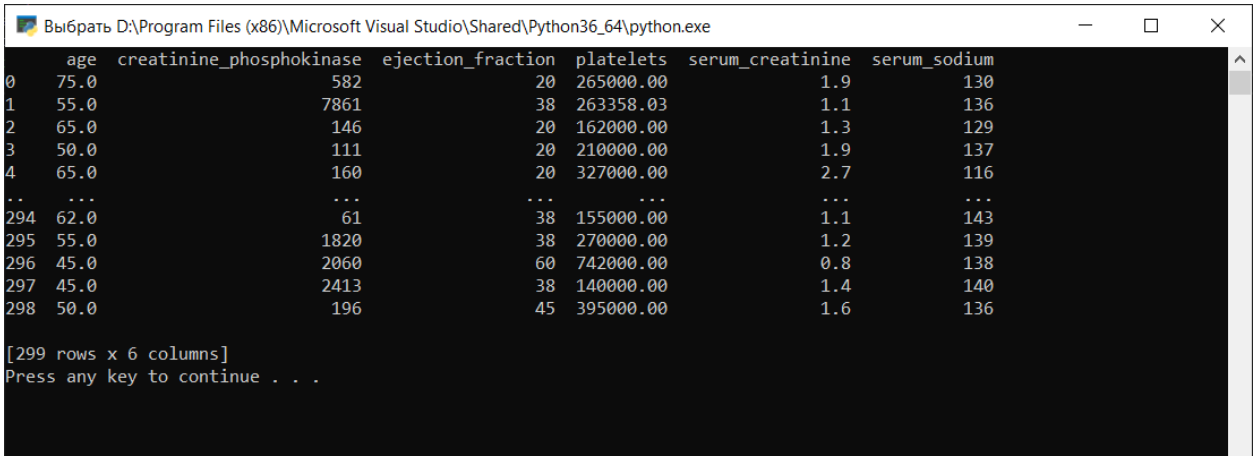

3. Построила гистограммы признаков

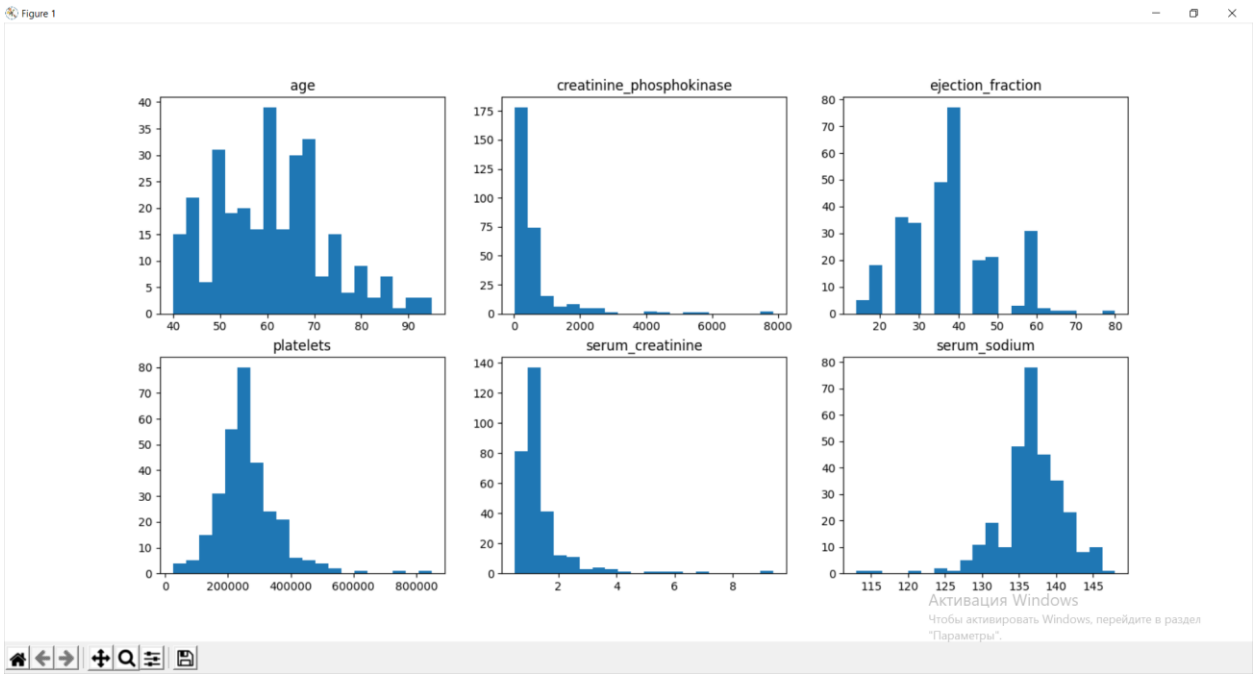

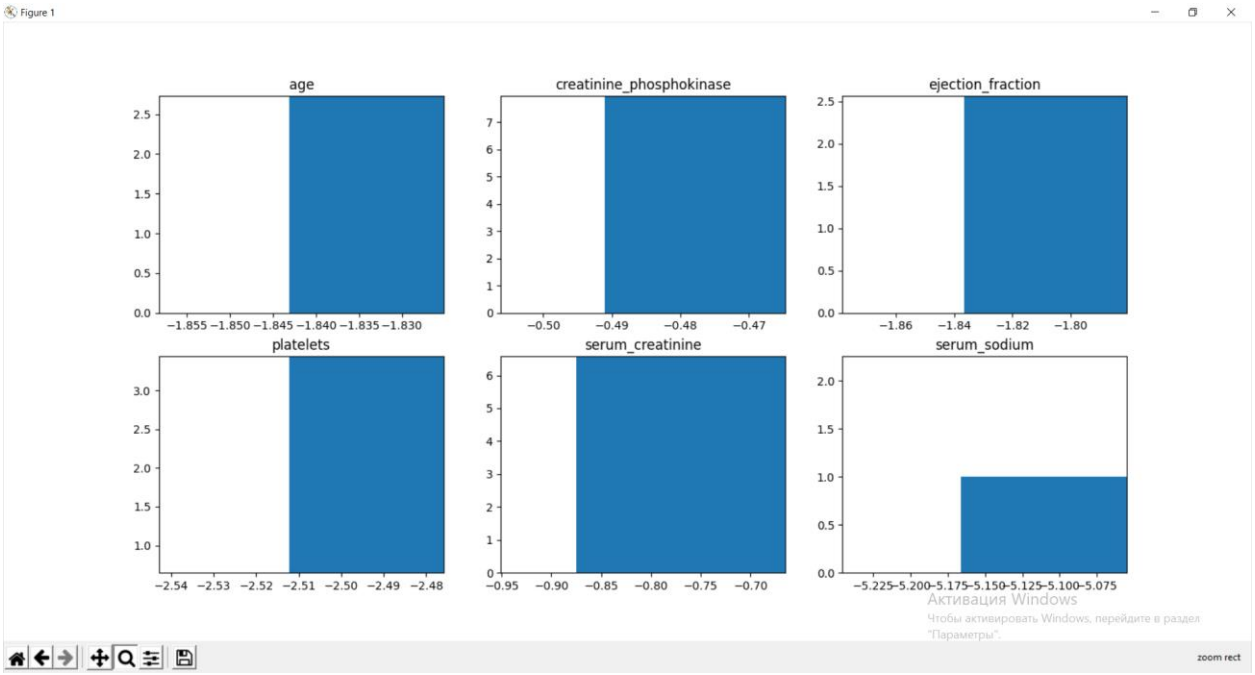

На основании гистограмм определила диапазоны значений для каждого из признаков, а также возле какого значения лежит наибольшее количество наблюдений. Приближения:

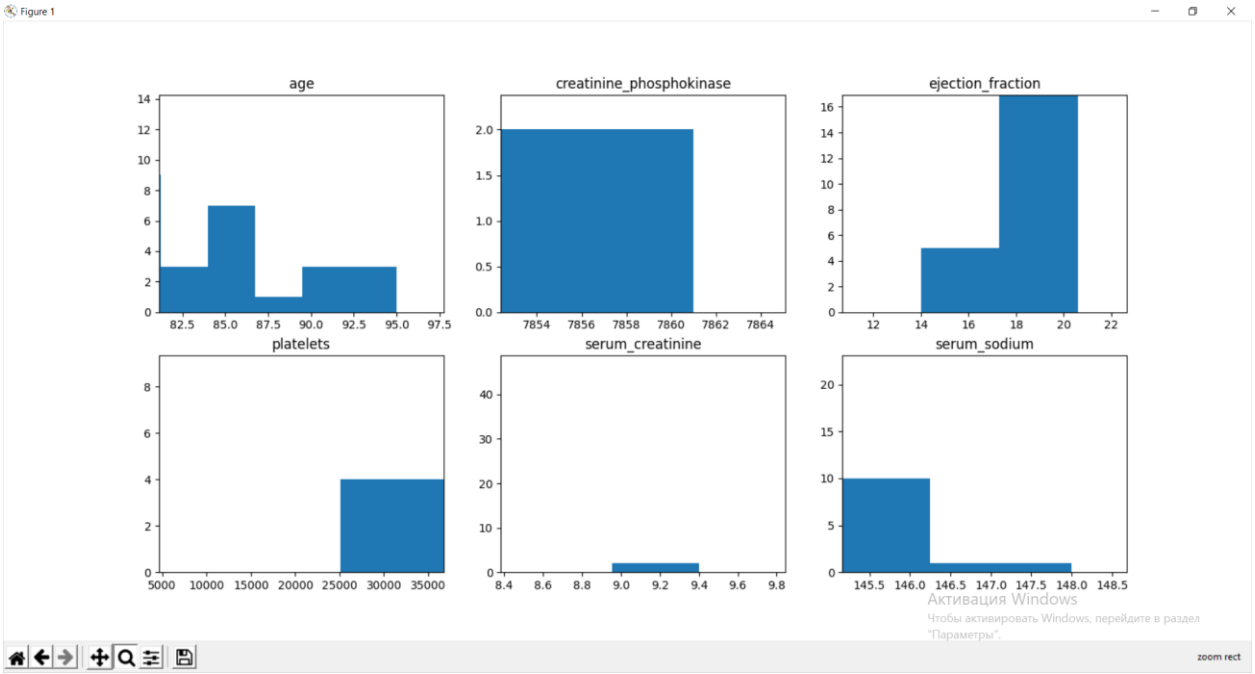

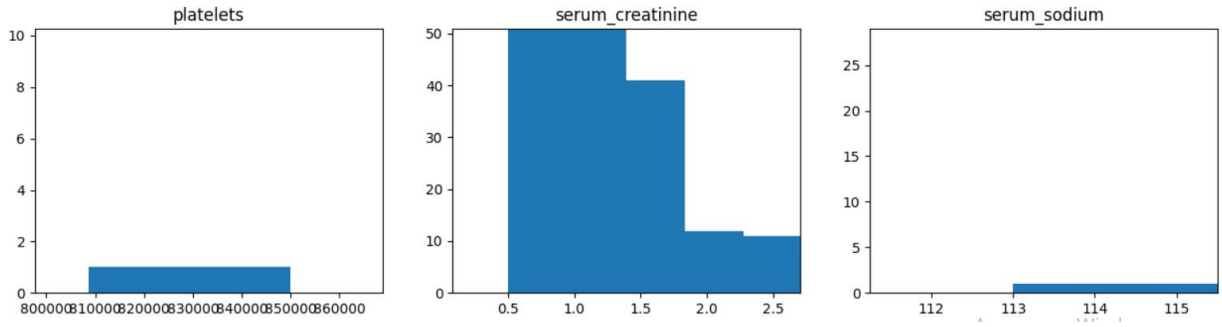

Стандартизация данных:

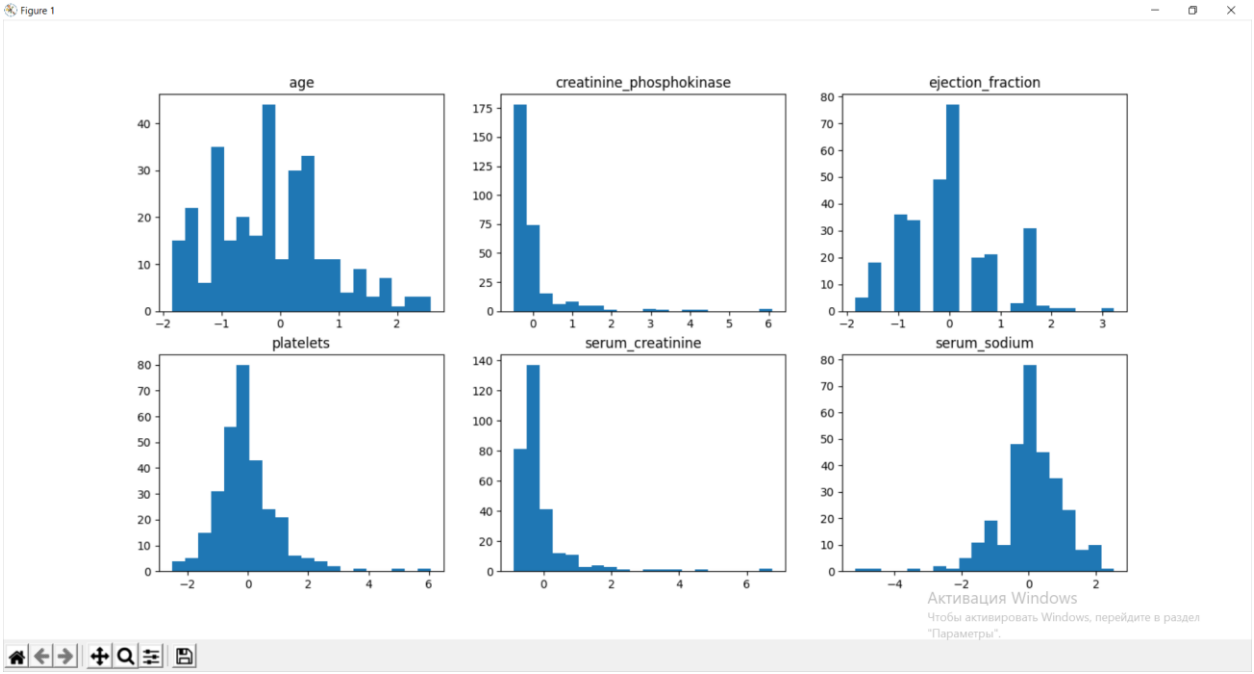

5. Рассчитала мат. ожидание и СКО до и после стандартизации. На основании этих значений выведила для каждого признака формулы по которым они стандартизировались.

6. Сравнила значения из формул с полями mean_ и var_ объекта scaler

До стандартизации:

```
print(np.mean(data, axis=0))
```

[6.08338930e+01 5.81839465e+02 3.80836120e+01 2.63358029e+05

1.39387960e+00 1.36625418e+02]

```
print(np.var(data, axis=0))
```

[1.41013284e+02 9.38309881e+05 1.39595016e+02 9.53367655e+09
1.06663177e+00 1.94048389e+01]

До стандартизации Scaler (получилось так же):

```
print(scaler.mean_)
```

[6.08338930e+01 5.81839465e+02 3.80836120e+01 2.63358029e+05
1.39387960e+00 1.36625418e+02]

```
print(scaler.var_)
```

[1.41013284e+02 9.38309881e+05 1.39595016e+02 9.53367655e+09
1.06663177e+00 1.94048389e+01]

После стандартизации:

```
print(np.mean(data_scaled, axis=0))
```

[5.70335306e-16 0.00000000e+00 -3.26754603e-17 7.72329061e-17
1.42583827e-16 -8.67384945e-16] Есть нулевое значение

```
print(np.var(data_scaled, axis=0))
```

[1. 1. 1. 1. 1. 1.]

Формула:

$$X_{i,stand} = \frac{X_i - M_i}{\text{СКО}_i}$$

После стандартизации 150:

```
print(np.mean(data_scaled[:150,:], axis=0))
```

```
[ 1.30266168e-16  2.36847579e-17  1.18423789e-16
8.88178420e-17
 -1.30266168e-16 -3.06717614e-15]
```

```
print(np.var(data_scaled[:150,:], axis=0))
```

```
[1. 1. 1. 1. 1. 1.]
```

Приведение к диапазону

1. Привела данные к диапазону используя MinMaxScaler
2. Построила гистограммы для признаков и сравнила с исходными данными

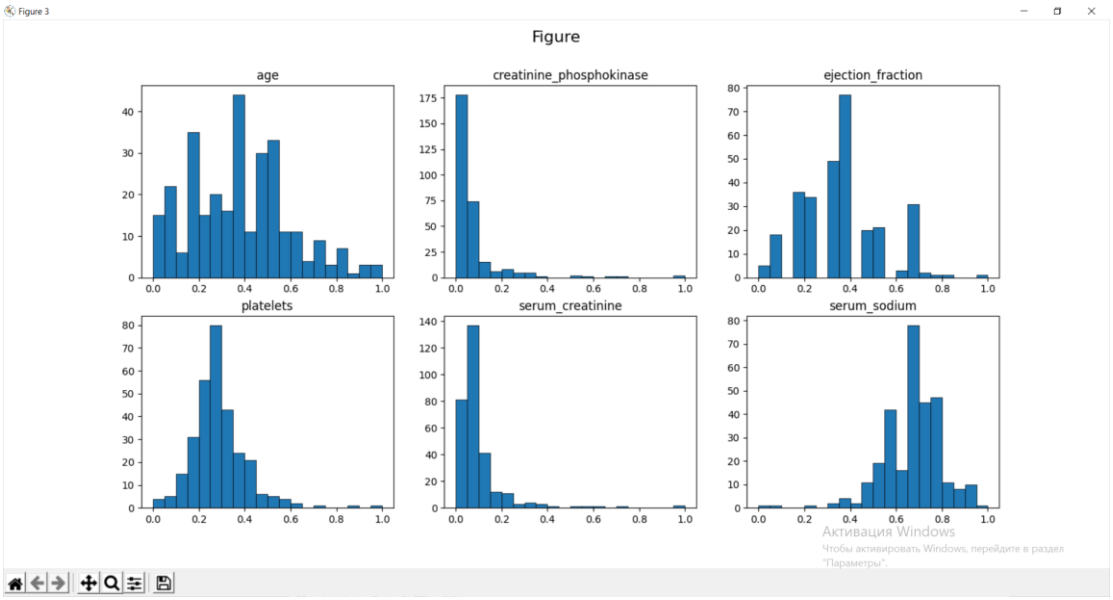

Диапазон стал [0..1]

3. Через параметры MinMaxScaler определила минимальное и максимальное значение данных для каждого признака

[4.00e+01 2.30e+01 1.40e+01 2.51e+04 5.00e-01 1.13e+02]

[9.500e+01 7.861e+03 8.000e+01 8.500e+05 9.400e+00 1.480e+02]

4. Аналогично трансформировала данные используя MaxAbsScaler и RobustScaler. Построила гистограммы. Определила к какому диапазону приводятся данные.

```
max_abs_scaler = preprocessing.MaxAbsScaler().fit(data)
data_max_abs_scaler = max_abs_scaler.transform(data)

robust_scaler = preprocessing.RobustScaler().fit(data)
data_robust_scaler = robust_scaler.transform(data)

plot_hists(data_max_abs_scaler)
plot_hists(data_robust_scaler)
```

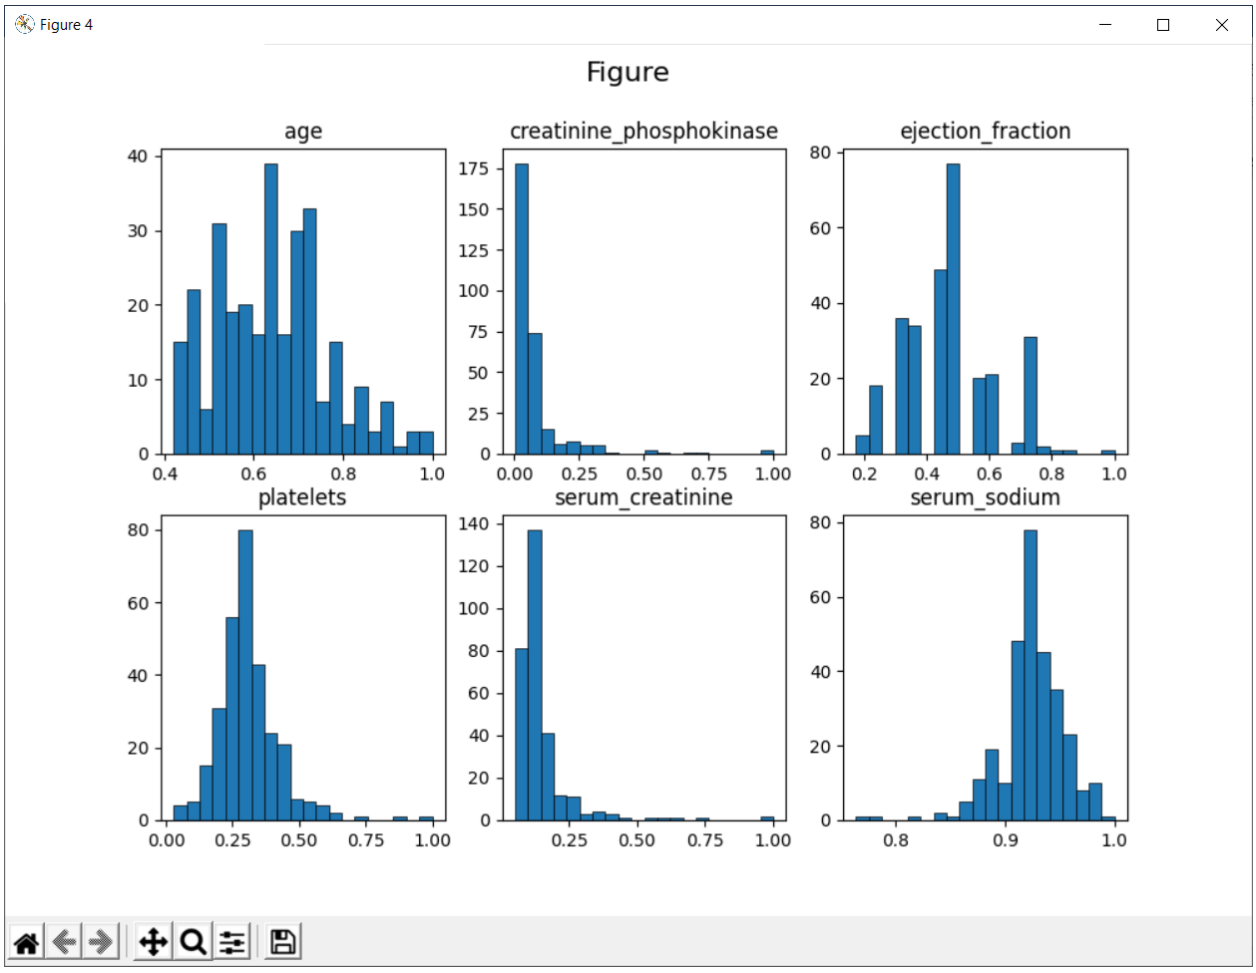

MaxAbsScaler

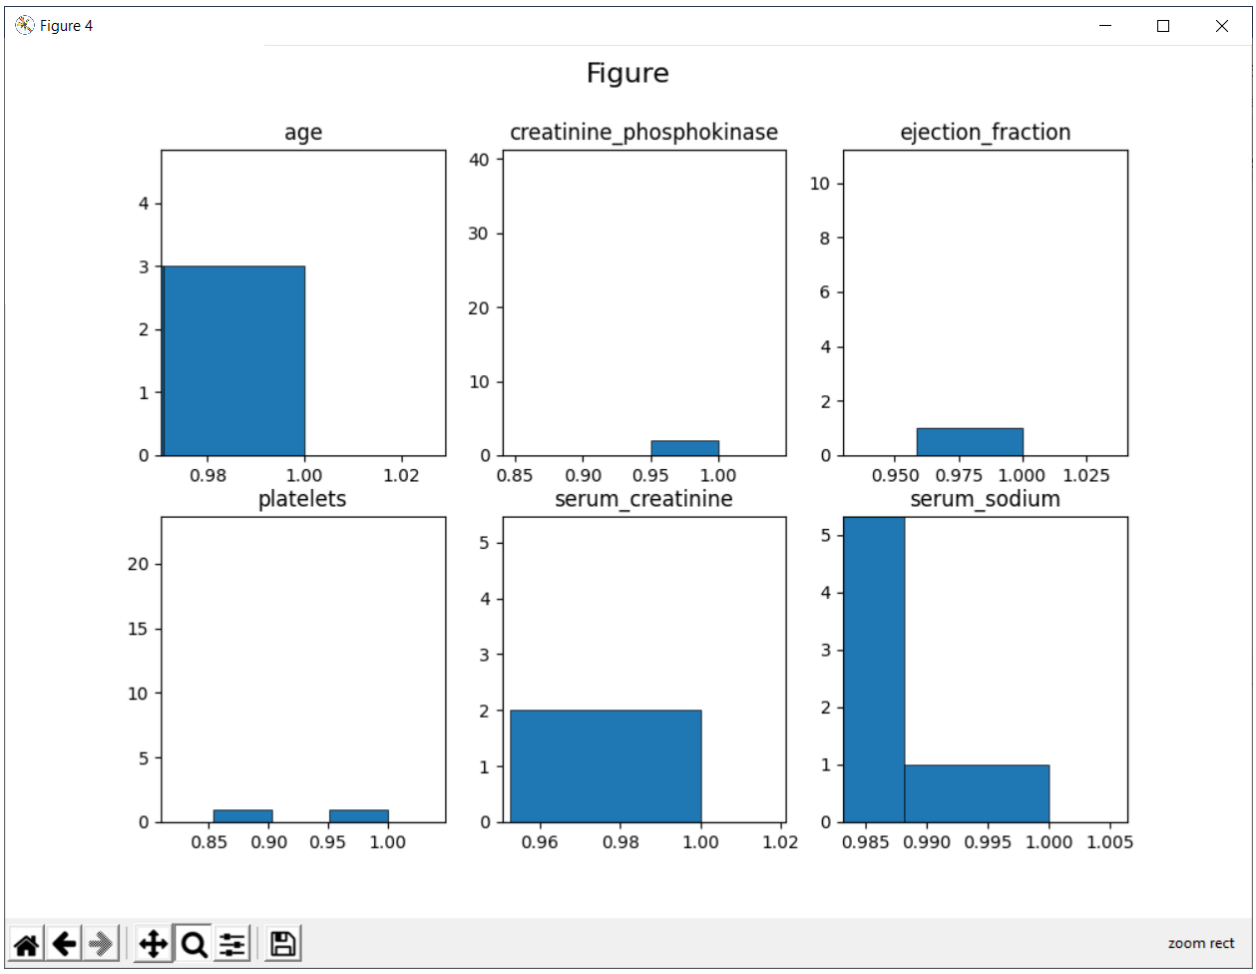

MaxAbsScaler

По гистограммам видно, что он приводит верхнюю границу диапазона к 1

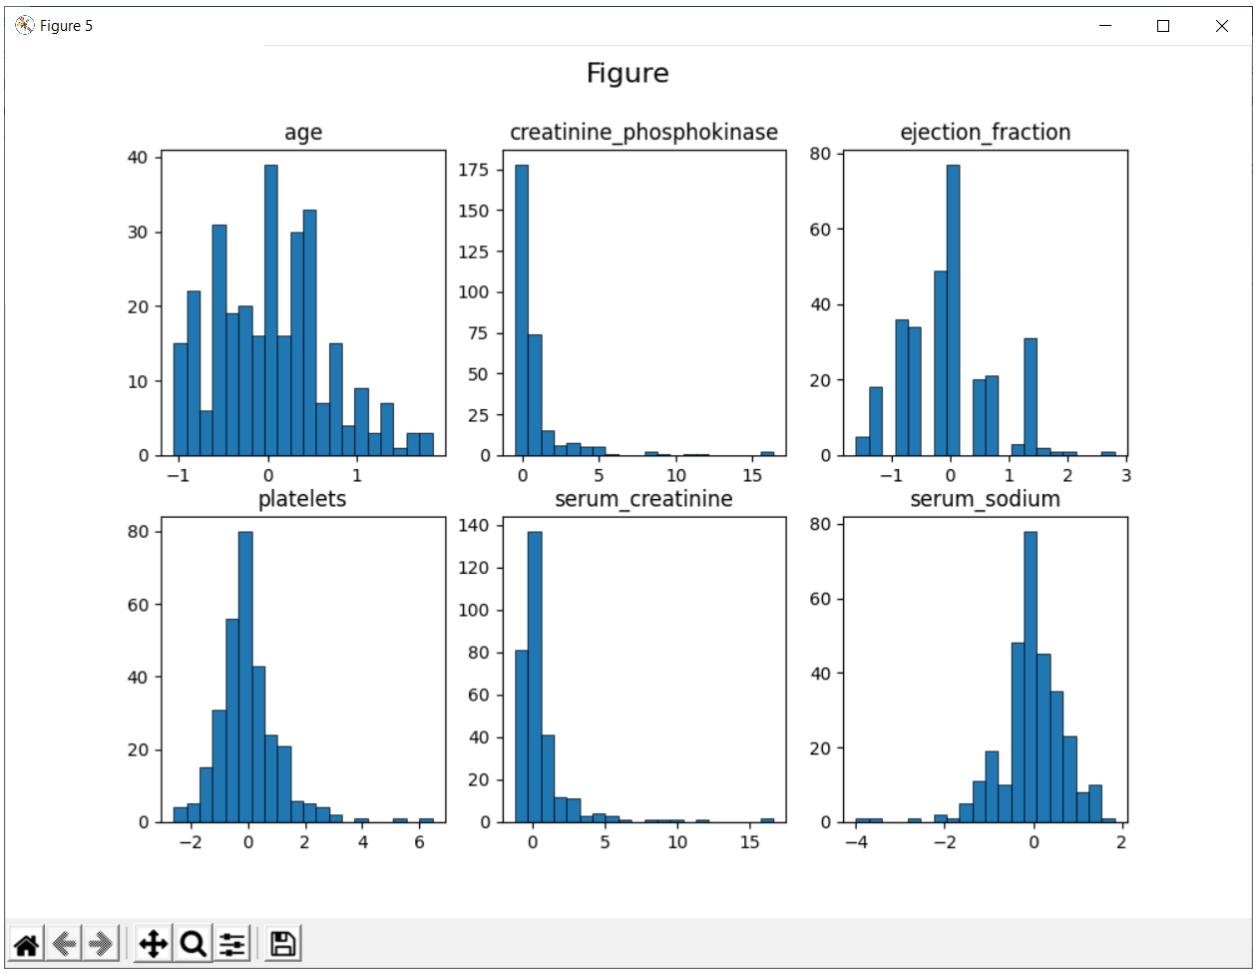

RobustScaler

Приводит среднее и медиану к 0, а среднее отклонение – к 1.

4. Напишите функцию, которая приводит все данные к диапазону [-5 10]

```
range_scaler = preprocessing.MinMaxScaler().fit(data)
data_range_scaler = range_scaler.transform(data)*15-5
```

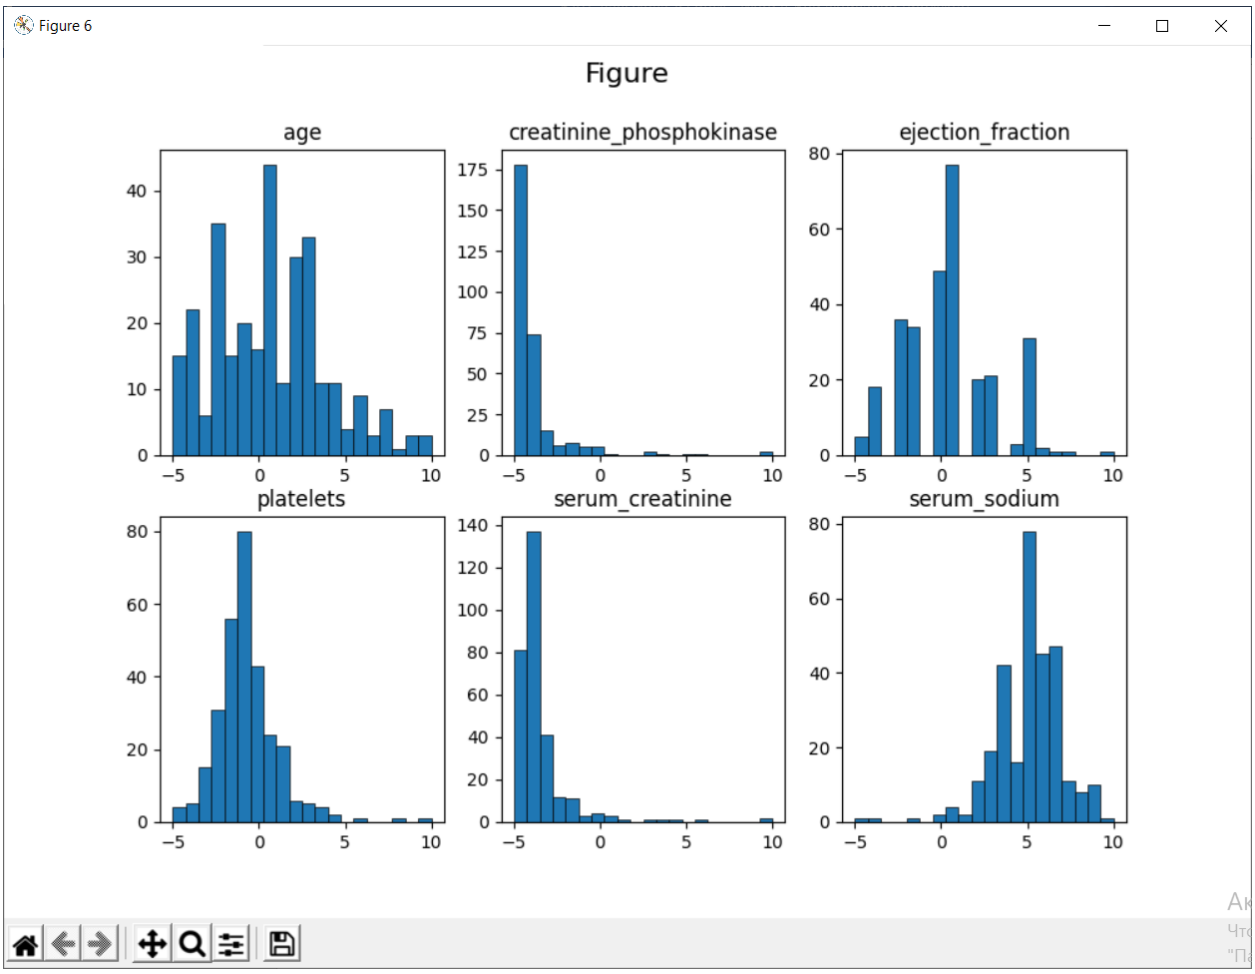

Нелинейные преобразования

1. Приведите данные к равномерному распределению используя QuantileTransformer
2. Постройте гистограммы и сравните с исходными данными

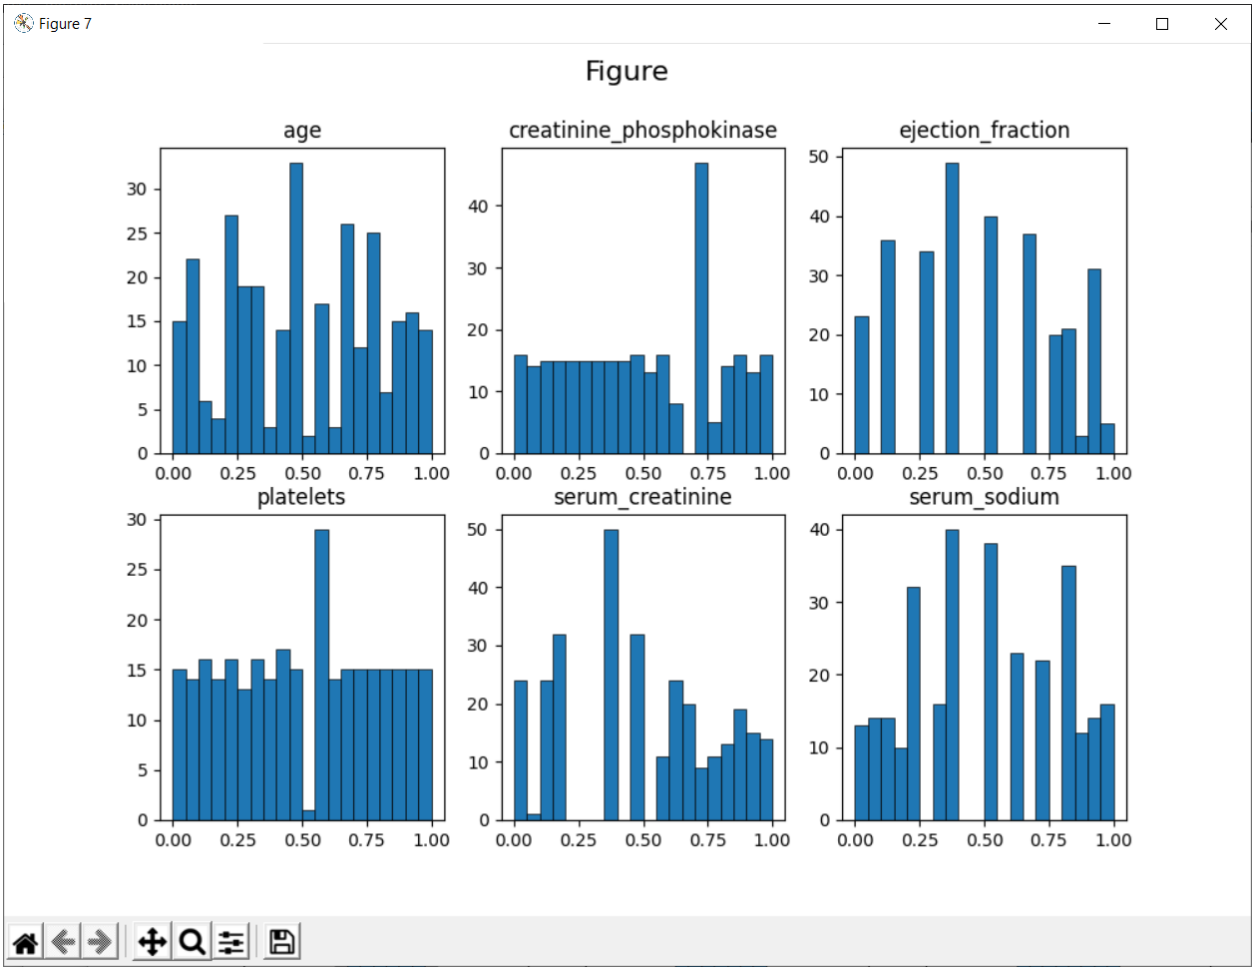

3. Определите, как и на что влияет значение параметра n_quantiles
Влияет на частоту дискретизации -> приближение к равномерному распределению.
4. Приведите данные к нормальному распределению передав в QuantileTransformer параметр output_distribution=‘normal’

```
quantile_transformer = preprocessing.QuantileTransformer(n_quantiles = 100,
random_state=0, output_distribution='normal').fit(data)
data_quantile_scaled2 = quantile_transformer.transform(data)
```

5. Постройте гистограммы и сравните с исходными данными

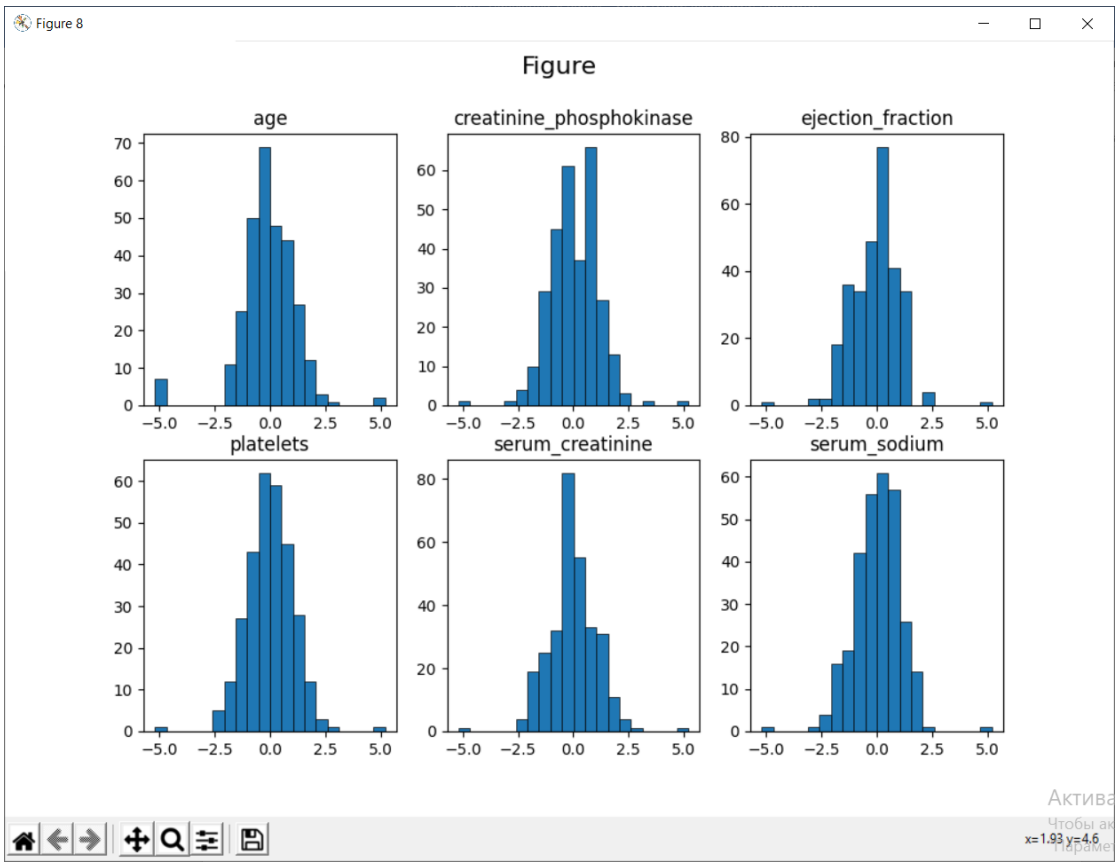

6. Самостоятельно приведите данные к нормальному распределению используя PowerTransformer

```
power_scaled = preprocessing.PowerTransformer().fit(data)
data_power_scaled = power_scaled.transform(data)
```

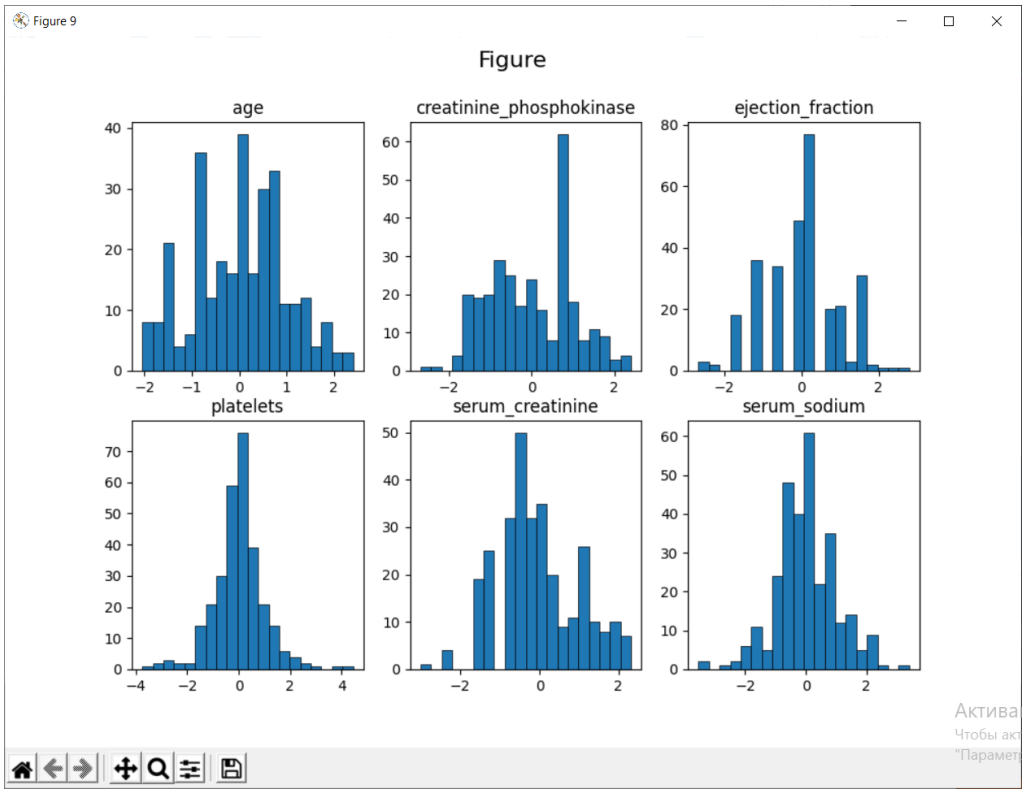

Дискретизация признаков

1. Проведите дискретизацию признаков, используя KBinsDiscretizer

2. Постройте гистограммы. Объясните полученные результаты

```
discret = preprocessing.KBinsDiscretizer(n_bins=[3, 4, 3, 10, 2, 4],
encode='ordinal').fit(data)
data_discret = discret.transform(data)
```

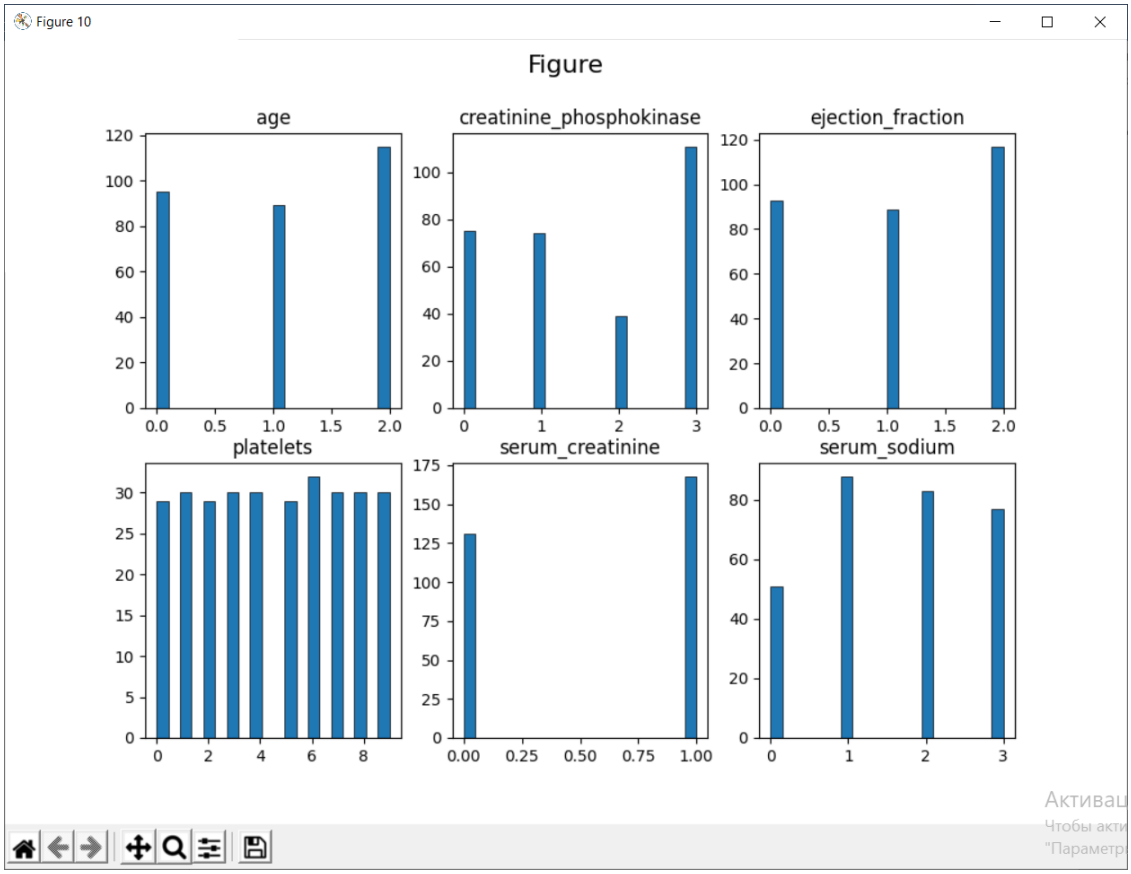

3. Через параметр bin_edges_ выведите диапазоны каждого интервала для каждого признака

print(discret.bin_edges_)

[array([40., 55., 65., 95.])

array([23. , 116.5, 250. , 582. , 7861.])

array([14., 35., 40., 80.])

array([25100., 153000., 196000., 221000., 237000., 262000., 265000.,

285200., 319800., 374600., 850000.])

array([0.5, 1.1, 9.4]) array([113., 134., 137., 140., 148.])]

Вывод

Ознакомилась с методами предобработки данных из библиотеки Scikit Learn, а именно стандартизацией, приведением к диапазону, нелинейными преобразованиями и дискретизацией данных.